

**MANUSCRITO DE LA INVESTIGACIÓN:*****PRONÓSTICO DEL PRECIO MENSUAL DE LA FRESA: UN  
ANÁLISIS COMPARATIVO.***Terrones Morones Juan Antonio<sup>1</sup>

<sup>1</sup>Programa para la Formación de Nuevos Investigadores. DICEA. Universidad Autónoma Chapingo, Estado de México.

**RESUMEN**

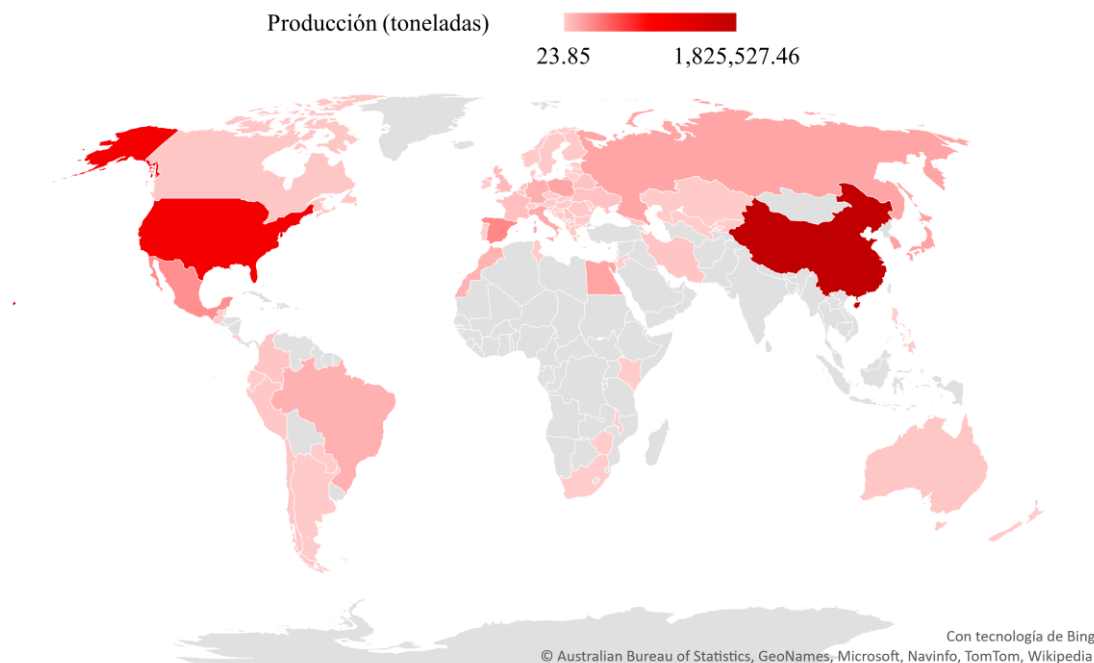
En 2016, México fue el segundo exportador de fresa a nivel mundial. La cantidad que exportó ascendió a 253.7 miles de toneladas, de las cuales 247.9 fueron exportadas a los Estados Unidos. La producción de fresa representó 1.14% del PIB agrícola nacional durante 2016. El objetivo de esta investigación fue la comparación de 3 modelos, con el fin realizar el mejor pronóstico del precio promedio mensual de la fresa. Se comparó un modelo ARIMA estacional, un modelo de regresión múltiple y un modelo de suavizamiento exponencial Holt-Winters. Fueron utilizados datos del precio promedio mensual de la fresa de la central de abastos de la Ciudad de México, desde enero de 1998 a diciembre de 2019. Los resultados indican, por un lado, que el método Holt-Winters y el modelo de regresión múltiple producen el mejor pronóstico, pues tienen el menor RMSE, sin embargo, sufren de autocorrelación, por lo que los límites de confianza del pronóstico estarán sesgados. Por otra parte, el modelo ARIMA estacional tiene las propiedades estadísticas de ruido blanco, aunque produce pronósticos con un mayor RMSE, se selecciona como el mejor modelo para pronosticar el precio mensual de la fresa.

**Palabras clave:** Precio de la fresa, pronóstico, ARIMA estacional, Holt-Winters, series de tiempo.

## Introducción

A nivel mundial, la producción de fresa fue de casi 3.5 millones de toneladas en 1994, de las cuales, México sólo producía poco más de 95 mil toneladas (2.7%), para 2019 la producción alcanzó cerca de 9 millones de toneladas, lo que significa que tuvo una tasa de crecimiento promedio de anual de 3.8%, México, por su parte, produjo 861.3 miles de toneladas, que representó un 9.7% de la producción mundial y tuvo una tasa de crecimiento promedio anual de 9.2%, mucho mayor que la tasa mundial (FAOSTAT, 2021).

**Figura 1.** Producción mundial de fresa, promedio 1994 a 2019.




Fuente: Elaboración propia a partir de datos de FAOSTAT (2021).

Considerando el periodo 1994 a 2019, en promedio, el mayor productor a nivel mundial es China con 1.82 millones de toneladas, le siguen los Estados Unidos con 1.06 millones de toneladas, España con 308 mil toneladas y México con 273 mil toneladas, representando un 30.3%, 17.6%, 5.1% y 4.5%, como proporción de la producción mundial respectivamente (FAOSTAT, 2021).

A nivel nacional la producción nacional de fresa aportó 1.14% del PIB agrícola para 2016, la mayoría de la producción nacional se destina al mercado externo, cerca de un 90% a los Estados Unidos de América (SAGARPA, 2017). Tomando en cuenta el promedio de las exportaciones de fresa desde 1994 hasta 2019, México es el tercer exportador mundial de fresa, encontrándose detrás de España, como primer exportador y Estados Unidos de América, como el segundo (FAOSTAT, 2021).

**Figura 2.** Exportaciones promedio por país, 1994 a 2019.




Fuente: Elaboración propia a partir de datos de FAOSTAT (2021).

Durante 2016, la producción nacional ascendió a 468 mil toneladas, de las cuales, Michoacán produjo el 72.9%, Baja California 15.1%, Guanajuato 8% y el resto de la producción otros estados (SIAP, 2017). Durante ese año, la mayor parte de la producción fue en los meses de mayo y junio, poco más del 40% de la producción en 2016 ocurrió en este par de meses, posteriormente, la producción comenzó a descender hasta llegar a un mínimo en octubre, donde solo se produjo el 1.1%. Similarmente, el precio de la fresa se ve afectado por la producción de esta, ya que, durante junio, el precio tiene una caída a \$13.7/kg, luego, el precio comienza a incrementarse hasta llegar a \$32.7/kg (SIAP, 2017).

(espacio en blanco)


**Figura 3.** Comportamiento del precio y la distribución de la producción de fresa en 2016.



Fuente: Elaboración propia a partir de datos de SNIIM (2021) y SIAP (2017).

Como en la gran mayoría de los productos agropecuarios, la estacionalidad está presente en el precio de la fresa, en el mes de septiembre el precio llega a su máximo, en contraste con marzo, donde el precio tiene una contracción, la figura 4 muestra el comportamiento estacional del precio, considerando el periodo desde enero 1998 hasta diciembre 2019.

**Figura 4.** Gráfico polar para estacionalidad, precio 1998 a 2019.




Fuente: Elaboración propia a partir de datos de SNIIM (2021).

Al analizar los índices estacionales del precio de la fresa durante enero 1998 a diciembre de 2019, se observa una marcada estacionalidad, en general, se espera un precio máximo durante

septiembre (42% por encima de la tendencia estimada) y un mínimo durante marzo (30% menor a la tendencia estimada).

**Figura 5.** Índices estacionales del precio de la fresa.



Fuente: Cálculo y elaboración propia a partir de datos de SNIIM (2021).

De acuerdo con Santos-Ramos et al (2017), la estacionalidad en la actividad agropecuaria se puede deber a factores relacionados con el ciclo biológico de cada especie o cultivo, a factores climáticos regionales, así como a factores de tipo cultural y social de cada región (Santos-Ramos et al, 2017).

Los modelos de pronóstico son importantes para los economistas empresariales ya que los ayudan a predecir las ventas, población, ingresos futuros de las empresas y sobre la evolución de la actividad económica. La precisión de los pronósticos proporciona una base para la mejor toma de decisiones de todo tipo (Hill et al, 2018).

La aplicación de estos modelos ha sido aplicada ampliamente en diversos contextos, Luis-Rojas et al., (2019) estiman un modelo SARIMA (0,1,1)(1,0,1)<sub>12</sub> para pronosticar el precio promedio del huevo blanco al productor, utilizando datos mensuales de 2000 a 2016, los autores obtienen un MAPE del 12.38%, concluyendo que el modelo tiene buena capacidad predictiva. Ruiz et al., (2019) analizan el precio de la manzana mediante un modelo SARIMA (2,1,0)(1,1,0)<sub>12</sub>, utilizando una serie mensual de 1998 a 2017, se obtiene un error relativo de 2%, el autor concluye que el modelo posee un pronóstico ideal. Marroquín y Chalita (2011) usan la metodología Box-Jenkins para pronosticar el precio del jitomate, se encuentra al modelo ARIMA (23,0,1) como el mejor, utilizan una serie de datos de 1998 a 2008,

concluyen que el modelo ARIMA se puede utilizar para pronosticar los precios futuros a partir del pasado. Carrasco (2020) estima un SARIMA  $(1,0,0)(0,1,1)_{12}$  y un ARIMA  $(1,0,1)$  para pronosticar la producción de limón y plátano, respectivamente, encuentra un MAPE de 22.86% y 18.59% respectivamente. Banás y Utnik-Banás (2021) realizan una comparación de tres modelos: ARIMA, SARIMA y SARIMAX para pronosticar el precio de la madera a corto plazo, los autores encuentran una similitud en los pronósticos en un horizonte de un trimestre, mientras que en horizontes más amplios los modelo SARIMA y SARIMAX son mejores. Guleryuz (2021) realiza una comparación entre un modelo ARIMA, un modelo de ajuste exponencial de Brown y un modelo de Redes Neuronales, con el fin de pronosticar el brote de COVID-19 en Turquía, el autor encuentra al modelo ARIMA como el mejor para realizar pronósticos. Sabu y Kumar (2020) realiza una comparación de un modelo SARIMA, un método estacional Holt-Winters y un modelo de LSTM para pronosticar el precio de las arecanuts, los autores encuentran al modelo LSTM como el mejor, ya que tiene un menor RMSE.

El objetivo de esta investigación es la comparación de 3 modelos, ARIMA estacional, método Holt-Winters y regresión múltiple, con el fin de obtener el mejor modelo para realizar pronósticos del precio mensual de la fresa, durante el periodo de enero 1998 a diciembre 2019, mediante el análisis de las medidas de precisión del pronóstico.

## Metodología

En este estudio, fue utilizada la serie de datos del precio mensual de la fresa en la central de abastos de la Ciudad de México desde enero de 1994 hasta diciembre de 2019, obtenida del SNIIM. La serie fue dividida en 2 partes, enero 1994 hasta diciembre 2014 y enero 2015 a diciembre 2019, utilizada para la estimación y el pronóstico de esta, respectivamente.

Posteriormente, se aplicó la metodología Box-Jenkins, la cual, de acuerdo con Green (2008) considera los siguientes pasos:

- 1) Transformar satisfactoriamente los datos para obtener una serie estacionaria. Este paso suele consistir en tomar las primeras diferencias, los logaritmos, o ambos, para

obtener una serie cuya función de autocorrelación muestre finalmente el decaimiento exponencial característico de una serie estacionaria. 2) Estimar los parámetros del modelo ARMA resultante, generalmente por mínimos cuadrados no lineales. 3) Generar el conjunto de residuos del modelo estimado y verificar que se asemejan satisfactoriamente a una serie de ruido blanco. Si no es así, especifique el modelo de nuevo y vuelva al paso 2. 4) El modelo puede utilizarse ahora con fines de previsión. (pág. 727)

Para verificar la ausencia de raíz unitaria, se aplicaron las pruebas de Dickey-Fuller Aumentada (ADF) y la KPSS (Hill et al., 2018, y Green, 2008):

Para el caso de ADF la hipótesis nula es  $H_0$ : La serie tiene raíz unitaria;  $\gamma = 1$  vs  $H_1$ :  $\gamma < 1$ .

**Cuadro 1.** Pruebas de estacionariedad de Dickey-Fuller Aumentada.

Modelo	Prueba ADF	Significado de la $H_1$
$\Delta y_t = \alpha + \gamma y_{t-1} + \sum_{s=1}^{p-1} \beta_s \Delta y_{t-s} + v_t$	Serie sin tendencia, pero con constante	$y_t$ es estacionaria sobre una media distinta de cero.
$\Delta y_t = \alpha + \gamma y_{t-1} + \lambda t + \sum_{s=1}^{p-1} \beta_s \Delta y_{t-s} + v_t$	Serie con tendencia y constante	$y_t$ es estacionaria sobre una tendencia determinística.
$\Delta y_t = \gamma y_{t-1} + \sum_{s=1}^{p-1} \beta_s \Delta y_{t-s} + v_t$	Serie sin tendencia ni constante	$y_t$ es estacionaria sobre una media cero.

Fuente: Elaboración propia a partir de Hill et al., (2018).

Se seleccionaron el número de rezagos de  $\Delta y_{t-s}$  acorde a la significancia del estadístico t, como lo sugieren Enders (2015) y Wooldridge (2010).

La prueba KPSS sigue la  $H_0$ : La serie es estacionaria;  $\eta = 0$  vs  $H_1$ :  $\eta \neq 0$ .

$$y_t = \alpha + \beta t + \eta \sum_{i=1}^t z_i + \varepsilon_t, \quad t = 1, \dots, T$$

Donde  $\varepsilon_t$  es una serie estacionaria y  $z_t$  es una i.i.d. serie estacionaria con media cero y varianza uno.



La selección del mejor modelo ARIMA se realizó utilizando el Criterio de Información de Akaike (AIC) (Box et al., 2015):

$$AIC = \frac{-2 \ln(L) + 2r}{n}$$

Donde  $L$  es la estimación de máximo verosimilitud,  $r = p + q + 1$  es el numero de parámetros estimados y  $n$  es el número de datos.

El modelo multiplicativo general ARIMA estacional es el siguiente (Box et al., 2015):

$$\phi_p(B)\Phi_P(B^s)\nabla^d\nabla_s^D y_t = \theta_q(B)\Theta_Q(B^s)a_t \quad (1)$$

Donde:

$a_t$  es un proceso de ruido blanco.

$y_t$  es la serie de tiempo a pronosticar, en este caso, el precio mensual de la fresa.

$B$  es el polinomio de  $j$  rezagos, tal que  $B^j y_t = y_{t-j}$

$\phi_p(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$  y  $\theta_q(B) = 1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q$  son polinomios de grado  $p$  y  $q$ , respectivamente.

$\Phi_P(B^s) = 1 - \Phi_1 B^s - \Phi_1 B^{2s} - \dots - \Phi_P B^{Ps}$  y  $\Theta_Q(B^s) = 1 + \Theta_1 B^s + \Theta_1 B^{2s} + \dots + \Theta_P B^{Qs}$  son polinomios estacionales de grado  $P$  y  $Q$ , respectivamente.

$\nabla^d = (1 - B)^d$  y  $\nabla_s^D = (1 - B^s)^D$  : son los tipos de diferenciación, en niveles y estacional de la serie  $y_t$ , respectivamente,  $s$  es la frecuencia de los datos.

También, se ajustó el modelo Holt-Winters aditivo, el cual tiene la siguiente representación (Hyndman y Athanasopoulos, 2021).

$$y_{t+h} = \ell_t + hb_t + s_{t+h-m(k+1)} \quad (2)$$

$$\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$$



$$s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$$

Donde:

$\ell_t, b_t$  y  $s_t$ , son las ecuaciones para el nivel, la tendencia y estacionalidad, respectivamente.  $\alpha, \beta^*$  y  $\gamma$ , son los parámetros a estimar de suavizamiento de nivel, tendencia y estacionalidad, respectivamente,  $y_t$  y  $m$ , son la serie de tiempo y la frecuencia de los datos, respectivamente.  $h$  es el número de periodos a pronosticar,  $k$  es la parte entera de  $(h - 1)/m$ .

En este caso, R Studio selecciona aquel modelo que tenga el menor suma de cuadrados de los errores.

Por último, se modela la serie del precio mensual de la fresa mediante un modelo de regresión lineal múltiple considerando tendencia lineal y estacionalidad determinista (Diebold, 2019):

$$y_t = \delta_0 + \delta_1 time + \sum_{i=1}^s \mu_i \cdot D_{it} + \varepsilon_t \quad (3)$$

Donde:

$y_t, time, D_{it}$  y  $\varepsilon_t$ , son las variables de serie de tiempo a pronosticar, tiempo, variables dummies estacionales y error, respectivamente.  $\delta_0, \delta_1$  y  $\mu_i$ , son los coeficientes del intercepto, pendiente de tendencia y de estacionalidad, respectivamente.

Con el objetivo de seleccionar el mejor modelo de pronóstico, fueron utilizados como criterios los siguientes (Hanke, 2010):

Raíz cuadrada del error cuadrado medio (RMSE):  $RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$ , Error


porcentual medio absoluto (MAPE):  $MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{|y_t|}$ , Error porcentual medio (MPE):

$MPE = \frac{1}{n} \sum_{t=1}^n \frac{y_t - \hat{y}_t}{y_t}$  y se utilizó la función de autocorrelación de los residuales para descartar/encontrar ruido blanco.

## Resultados y discusión

Para implementar la metodología Box-Jenkins es necesario que la serie de tiempo a pronosticar sea estacionaria, al observar la serie en niveles (Figura 6) se nota una tendencia positiva, así como un comportamiento repetitivo anualmente, es decir, la estacionalidad, a simple vista se puede inferir que la serie es no estacionaria.

**Figura 6.** Precio promedio mensual de la fresa, enero 1998 a diciembre 2019.



Fuente: Elaboración propia a partir de datos de SNIIM (2021).

Al aplicar la diferencia estacional, se observa a la serie del precio de la fresa sin tendencia, así como la estacionariedad de la serie.

**Figura 7.** Diferencia estacional del precio mensual de la fresa.



Fuente: Elaboración propia a partir de datos de SNIIM (2021).

Se aplicó la prueba ADF y la KPSS para verificar la estacionariedad. Los resultados indican que la serie en niveles es no estacionaria, al aplicar la diferencia estacional, la serie se vuelve estacionaria, por lo que es posible proseguir con la siguiente etapa .

**Cuadro 2.** Pruebas de estacionariedad.


	H <sub>0</sub> : La serie tiene raíz unitaria	H <sub>0</sub> : La serie es estacionaria
	Prueba ADF	Prueba KPSS
<b>Precio de la fresa</b>	Sin Tendencia tendencia ni intercepto	
<b>En niveles</b>	-0.1907 [0.1039]	[0.0100]
<b>Diferencia estacional</b>	-0.5492 [0.0000]	[0.1000]

Nota: los p value se muestran entre corchetes.

Fuente: Elaboración propia.

La siguiente etapa de la metodología Box-Jenkins es proponer los modelos tentativos a partir de la función de autocorrelación (ACF) y la función de autocorrelación parcial (PACF).

**Figura 8.** Función de autocorrelación (1) y autocorrelación parcial (2).



Fuente: Elaboración propia.

Al analizar la ACF se observan 4 primeros rezagos significativos, así como un rezago estacional, por ende, se consideran 4 rezagos en promedios móviles y 1 rezago estacional en promedio móvil. En la PACF se observa 1 primer rezago significativo y 1 rezago estacional significativo. Se propone un rezago autorregresivo y 1 rezago autorregresivo estacional.

De acuerdo con lo anterior, se proponen 4 modelos ARIMA tentativos: a)  $(3,0,0)(1,1,0)_{12}$ , b)  $(1,0,3)(0,1,1)_{12}$ , c)  $(2,0,4)(1,1,1)_{12}$  y d)  $(0,0,4)(0,1,1)_{12}$ .

Se identificaron los posibles órdenes autorregresivos y promedios móviles del modelo ARIMA, los resultados se presentan en el cuadro 3. De acuerdo con el Criterio de Akaike (AIC), el mejor modelo ARIMA estacional es  $(1,0,3)(0,1,1)_{12}$ .

**Cuadro 3.** Estimación de los modelos ARIMA estacional propuestos.

ARIMA estacional				
Estadístico	$(3,0,0)(1,1,0)_{12}$	$(1,0,3)(0,1,1)_{12}$	$(2,0,4)(1,1,1)_{12}$	$(0,0,4)(0,1,1)_{12}$
AIC	1153.290	1129.427	1134.011	1162.071
SSE	2470.446	2125.391	2104.954	2544.748
p-value	0.858	0.989	0.999	0.2396

Fuente: Elaboración propia.

Las estimaciones del modelo ARIMA estacional, Holt-Winters y la regresión múltiple, se presentan en el cuadro 4. Los resultados indican lo siguiente, el modelo que tiene mejor ajuste en la muestra de estimación es el ARIMA, indicando un menor RMSE y MAPE, así como es el modelo menos sesgado, ya que tiene menor MPE. Posteriormente le sigue el modelo Holt-Winters. El modelo de regresión lineal es quien tiene menor ajuste y mayor sesgo.

**Cuadro 4.** Medidas de precisión de los modelos estimados.


Medidas de precisión						
Modelo	Trainin set			Test set		
	RMSE	MAPE	MPE	RMSE	MAPE	MPE
(1)	3.053	10.239	-0.204	8.653	25.634	-20.378
(2)	3.611	13.671	-2.024	8.186	22.571	-11.474
(3)	3.483	12.132	-0.331	7.307	20.102	-10.126

Fuente: Elaboración propia.

Sin embargo, en la muestra de prueba, siendo esta donde se evalúa la capacidad predictiva de los modelos estimados, el ARIMA estacional es quien tiene un mayor RMSE y MAPE, así como ser el más sesgado, además, los 3 modelos están sobreestimando los valores al tener un valor lejano de cero y negativo en el MPE. El modelo Holt-Winters tiene el menor RMSE y MAPE, además, es el modelo con menor sesgo. Y el modelo de regresión lineal múltiple se encuentra en medio de los anteriores, ya que tiene un menor RMSE y MAPE que el ARIMA estacional, pero mayor que el modelo de regresión lineal múltiple.

Hasta ahora, el mejor modelo para pronosticar el precio de la fresa es el modelo Holt-Winters, sin embargo, para que los intervalos del pronóstico sean válidos, los modelos deben de cumplir el supuesto de ruido blanco, además, si existe autocorrelación en los residuales el pronóstico puntual no será el óptimo (Hyndman y Athanasopoulos, 2021; Diebold, 2019).

**Figura 9.** Función de autocorrelación de los residuales.



Fuente: Elaboración propia.

Al analizar la función de autocorrelación de los residuales se observa que sólo el modelo ARIMA estacional tiene ruido blanco. De acuerdo con lo anterior, se seleccionó al modelo ARIMA estacional como el mejor modelo para realizar pronósticos del precio mensual de la fresa.

## Conclusiones

La pronosticación del precio mensual de la fresa y de cualquier serie de tiempo requiere realizar un análisis detallado sobre los posibles modelos, ya que estos modelos pueden sufrir de correlación serial. En esta investigación se encuentra al modelo ARIMA estacional como

el mejor modelo, ya que sus residuales son ruido blanco y, por lo tanto, los pronósticos e intervalos de confianza son válidos.

## Bibliografía

Banas, J. y Utnik-Banas, K. (2021). Evaluating a seasonal autoregressive moving average model with an exogenous variable for short-term timber price forecasting. *Forest Policy and Economics*. Vol. 131. Doi: <https://doi.org/10.1016/j.forpol.2021.102564>

Box, G., Jenkins, G. M., Reinsel, G. C. y Ljung G. M. (2015). *Time series analysis: forecasting and control*. Fifth edition. Wiley.

Carrasco, C. F. (2020). Pronóstico de la producción de las principales frutas en la región de Piura. Un análisis econométrico con el método de Box-Jenkins. *Semestre Económico*, agosto-diciembre 2020; 09(2):31-44. Doi: <http://revistas.unap.edu.pe/seconomico/index.php/SECONOMICO/article/view/386/342>

Diebold, F. (2019). *Econometric data science a predictive modeling approach*. Department of Economics, University of Pennsylvania.

Enders, W. (2015). *Applied econometric time series*. Fourth edition. Wiley.

FAOSTAT. (2021). Datos. FAO. En línea. Disponible en: <http://www.fao.org/faostat/en/>

Greene, W. H. (2008). *Econometric analysis*. Sixth edition. Pearson.

Guleryuz, D. (2021). Forecasting outbreak of COVID-19 in Turkey; Comparison of Box–Jenkins, Brown’s exponential smoothing and long short-term memory models. *Process Safety and Environmental Protection*. Vol. 149. pp. 927-935. Doi: <https://doi.org/10.1016/j.psep.2021.03.032>

Hanke, J. E. y Wichern, D. W. (2010). *Pronósticos en los negocios*. novena edición. Pearson. México.

Hill, R. C., Griffiths, W. E. y Lim, G. C. (2018). *Principles of econometrics*. Fifth edition. Wiley.

Hyndman, R., Athanasopoulos, G. (2021). Forecasting principles and practice. Third edition. Otexts. En línea. Disponible en: <https://otexts.com/fpp3/>

Luis-Rojas, S., García-Sánchez, R. C., García-Mata, R., Arana-Coronado, O. A. y González-Estrada, A. (2019). Metodología Box-Jenkins para pronosticar los precios de huevo blanco pagados al productor en México. *Agrociencia* 53: 911-925.

Marroquín, M. G. y Chalita, T. L. E. (2011). Aplicación de la metodología Box-Jenkins para pronóstico de precios en jitomate. *Revista Mexicana de Ciencias Agrícolas* Vol.2 Núm.4. p. 573-577.

Ruiz, H. J. A., Barrios, P. G. y Gómez, G. A. A. (2019). Análisis del precio de la manzana mediante un modelo SARIMA. *Revista Mexicana de Ciencias Agrícolas*. Vol.10. número 2.

Sabuab, K. M. y Kumar, T.K. M. (2020). Predictive analytics in Agriculture: Forecasting prices of Arecanuts in Kerala. *Procedia Computer Science*. Vol. 171, pp. 699-708. Doi: <https://doi.org/10.1016/j.procs.2020.04.076>

SAGARPA. (2017). Planeación agrícola nacional 2017-2030. Fresa mexicana.

Santos-Ramos, M., Perea-Peña, M., Flores-Padilla, J. P. y Bobadilla-Soto, E. E. (2017). Estacionalidad de la producción y precios de cerdo en México. *Realidad económica*, pág. 27.

SIAP. (2017). Atlas agroalimentario 2017. Ciudad de México. En línea. Disponible en: [https://nube.siap.gob.mx/gobmx\\_publicaciones\\_siap/pag/2017/Atlas-Agroalimentario-2017](https://nube.siap.gob.mx/gobmx_publicaciones_siap/pag/2017/Atlas-Agroalimentario-2017)

SNIIM. (2021). Datos. SE. En línea. Disponible en: <http://www.economia-sniim.gob.mx/nuevo/>


Wooldridge, J. M. (2010). Introducción a la econometría un enfoque moderno. Cuarta edición. CENGAGE.



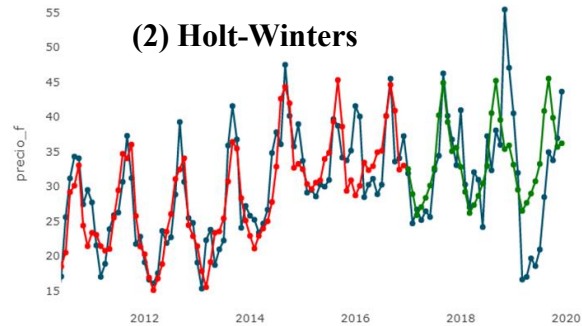
## Anexo 1. Ajuste y pronóstico de los modelos vs precio observado

Al estimar los modelos y realizar los pronósticos, se obtiene lo siguiente:

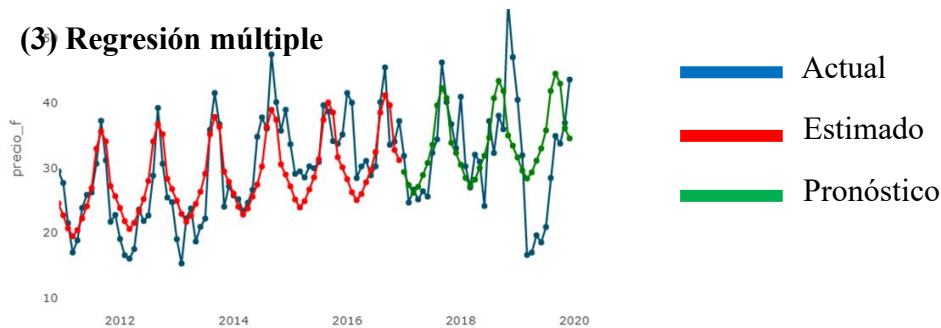
**(1) ARIMA estacional**



**(2) Holt-Winters**



**(3) Regresión múltiple**



Fuente: Elaboración propia a partir de R Studio.